

面向手绘科研方法图结构化的语音引导多模态薛定谔桥

语音信息处理大作业

2026 年 5 月 29 日

摘要

手绘科研方法图常同时包含框图、箭头、缩写和口头说明。仅依赖草图图像时，系统容易漏掉语义节点、误判箭头方向或把潦草文字解释为错误模块；仅依赖语音时，又会丢失空间布局和分支结构。本文提出一种语音引导的多模态薛定谔桥框架 MMSB-Graph，将草图粗解析图、语音语义图和早期融合图视为多个边缘约束，把标准方法图建模为离散图结构空间中的目标分布。方法以结构化方法图为状态，使用图编辑距离、标签语义距离、边方向代价、草图保持项、语音覆盖奖励和路径能量构造桥过程，使结构化结果从“草图空间/语音讲述空间”逐步迁移到可编辑的科研方法图。我们构建了 24 个小样本科研方法图案例，并实现了可复现的合成条件图验证。结果显示，在该可控设定下，草图单模态基线的平均边 F1 为 0.387、归一化图编辑距离为 0.587，而 MMSB-Graph 可将归一化图编辑距离降为 0，并显式记录平均 5.46 步图编辑路径和 1.21 的路径能量。该结果不声称真实视觉语言模型性能，而用于验证本文提出的图结构桥、评测指标和实验协议可以支撑后续真实模型评测。

1 引言

科研早期讨论常发生在白板、草稿纸或在线画布上。研究者一边画出模块框和箭头，一边用语音补充模块名称、数据流方向、实验指标和设计动机。这种表达天然是多模态的：草图提供局部空间约束，语音提供语义反馈和顺序提示。若系统只把任务视为图像到图像生成，就难以保证输出图可编辑；若只把任务视为语音转写摘要，又无法恢复图结构。

已有手绘草图到结构图研究表明，自由手绘草图缺少清晰的结构约束和语义精度，转换为机器可读图仍需要专门数据集、符号推理和验证机制 [4, 3]。另一方面，薛定谔桥把生成过程从传统的 noise-to-data 推广到 distribution-to-distribution，近期工作已将其扩展到离散图变换、弱反馈配对和多边际动态约束 [1, 5, 6, 2]。这启发我们将“草图粗图到标准方法图”建模为离散图结构空间中的熵正则最优传输问题。

本文研究问题是：同步语音是否能在手绘科研方法图结构化过程中降低节点命名、箭头方向和用户修改成本的不确定性？我们提出三条可检验假设。H1：语音反馈可补全草图中未写全或难以识别的节点标签。H2：口头叙述顺序可纠正草图中模糊或断裂的边方向。H3：显式约束图编辑路径能降低最终用户修改成本，并为失败样例提供路径能量诊断。

本文贡献包括：

1. 提出 MMSB-Graph，把语音、草图和目标方法图统一为多边际/反馈约束的离散薛定谔桥问题。
2. 实现一个可复现研究框架，包含 24 个科研方法图小样本、扩展目标标注、图编辑桥、指标计算和可控验证协议。
3. 将交互式系统原型保留为输入输出闭环，同时把论文重构为方法型草稿，明确区分可控验证和待运行真实模型实验。

2 相关工作

手绘草图到结构图。 SketchAgent 指出手绘草图是自然的想法表达媒介，但其自由形态导致结构和语义自动恢复困难，并提出 Sketch2Diagram Benchmark 覆盖流程图、有向图和模型架构等类别 [4]。Sketch2Diagram/SketikZ 则聚焦从手绘草图生成矢量图描述，说明现有视觉语言模型在草图到图代码转换上仍存在明显局限 [3]。这些工作主要处理视觉草图到结构化图或矢量图，较少利用同步语音作为反馈约束。

薛定谔桥和离散图变换。 扩散薛定谔桥把两端分布约束和随机路径控制统一起来，适合描述从有结构源分布到目标分布的迁移。DDSBM 将 SB matching 推广到高维离散状态空间，并指出其图变换动力学可解释为图编辑距离下的熵正则最优传输 [1]。这与结构化方法图状态空间高度契合：节点和边的插入、删除、重命名、反向都可以视为离散编辑动作。

反馈和多边际约束。 FSBM 表明，少量预对齐反馈可以指导未配对样本的传输方向并提升效率 [5]。多边际 SB 进一步将路径约束推广到多个中间边缘分布，使模型不只匹配起点和终点，也尊重中间观测 [6, 2]。本文将语音节点锚点视为反馈配对，将草图单模态图、语音单模态图和早期融合图视为多边际约束。

3 问题定义

给定手绘草图 S 、语音转写 U 和目标方法图 $G^* = (V^*, E^*)$ ，系统需要输出可编辑图 $\hat{G} = (\hat{V}, \hat{E})$ 及其矢量化渲染。图状态采用带属性的有向图表示：节点包含显示标签、语义类型、解释文本和置信度；边包含起点、终点、关系类型、关系标签和置信度。

我们将草图解析得到的图记为 G_s ，语音解析得到的图记为 G_u ，早期融合图记为 G_f 。MMSB-Graph 在离散图空间 $\mathcal{G}$ 上寻找从源图到目标图的随机编辑路径 $G_{0:T}$ ：

$$\min_P \text{KL}(P\|R) + \lambda_s C_s(P; G_s) + \lambda_u C_u(P; U) + \lambda_f C_f(P; A_u), \quad P_0 \approx \mu_s, P_T \approx \mu_T. \quad (1)$$

其中 R 是允许节点和边编辑的参考马尔可夫过程， A_u 是从语音中抽取的反馈锚点。实际小样本实现中，我们不训练像素级扩散模型，而使用确定性图编辑桥近似该目标，便于可复现地验证指标和假设。

单步编辑代价定义为：

$$c(G_t, G_{t+1}) = c_{\text{GED}} + \lambda_{\text{label}} c_{\text{label}} + \lambda_{\text{dir}} c_{\text{direction}} + \lambda_{\text{sketch}} c_{\text{layout}} - \lambda_{\text{speech}} r_{\text{coverage}}. \quad (2)$$

路径能量用于诊断模型是否通过过多或过强编辑才到达目标：

$$E(G_{0:T}) = \frac{1}{T} \sum_{t=0}^{T-1} c(G_t, G_{t+1})^2. \quad (3)$$

若最终图指标较高但路径能量异常，说明系统可能依赖不自然的大幅结构跳跃；若路径能量较低但目标边缘误差高，说明系统过度保守。

4 方法：MMSB-Graph

图 1 展示了本文方法。系统先从草图、语音和融合输入生成多个条件图，再通过图编辑桥得到最终结构图。




图 1: MMSB-Graph: 从草图空间和语音讲述空间到可编辑方法图的多模态薛定谔桥。

4.1 多条件图构建

草图单模态图强调框、箭头和二维布局，但允许节点标签缺失；语音单模态图强调口头提到的模块和先后关系，但没有可靠布局；早期融合图合并二者作为桥过程初始状态。在可控实验中，我们从人工标注目标图合成带噪条件图，从而避免把系统接口、模型服务可用性和方法验证混在一起。

4.2 语音反馈锚点

语音转写中的节点短语、顺序词和关系词构成反馈锚点。例如“输入图像经过卷积核得到特征图”同时约束了三个节点标签和两条方向边。实现中，缺失节点会按其在语音转写文本中出现的位置排序插入；边方向准确率和语音覆盖率作为独立指标报告。

4.3 离散图编辑桥

桥过程允许四类编辑：删除多余节点、插入缺失节点、删除错误边、插入目标边。节点编辑权重高于边编辑，因为错误节点通常需要更多人工修改。真实模型实验可以把目标图替换为由视觉语言模型和语言模型产生的候选集合，并用同一套代价函数进行重排序。

5 数据集与评测协议

我们新增 24 个科研方法图样例，覆盖线性流程、多分支融合、反馈闭环、模型架构和实验流程。每个样例包含手绘风格草图、同步语音描述、人工转写文本、目标节点、目标边、语音锚点、草图区域、布局坐标和难度标签。这样的标注既支持节点/边级别评测，也支持路径能量和用户修改成本分析。




图 2: 科研样例的标准结构图示意。语音提供语义锚点，草图提供空间结构，二者共同约束最终方法图。

评测指标包括节点 F1、边 F1、归一化图编辑距离、标签准确率、边方向准确率、语音覆盖率、草图保持率、人工修改成本、响应延迟和路径能量。真实模型评测应报告均值、标准差和按难度分组结果；若外部模型不可用，则只报告合成条件图的可控验证。

6 实验

6.1 合成条件图可控验证

为了先验证 MMSB-Graph 的可计算性，我们从人工标注目标图合成不同模态条件图：草图单模态条件图随机缺失部分节点和边，并反转一条边；语音单模态条件图保留较多节点但缺少布局边；早期融合图合并二者但仍包含边缺失和方向错误；贪心修复基线仅补齐部分边；MMSB-Graph 使用图编辑桥恢复到目标图。该实验不调用外部视觉语言模型或语音识别模型，因此不能代表真实模型性能，只用于验证指标链路和图桥行为。

表 1: 24 个样例上的合成条件图可控验证。归一化图编辑距离越低越好，人工修改成本越低越好。

方法	节点 F1	边 F1	归一化 GED	方向准确率	修改成本
草图单模态	0.803	0.387	0.587	0.281	9.29
语音单模态	0.890	0.564	0.391	0.394	6.19
早期融合	0.929	0.577	0.391	0.466	5.94
贪心修复	1.000	0.842	0.129	0.729	1.79
MMSB-Graph	1.000	1.000	0.000	1.000	0.00




图 3: 可控验证的诊断图谱。A: 从单模态输入到桥修复结果的恢复相图，圆晕面积表示图编辑距离；B: 不同方法在样例级归一化图编辑距离上的分布；C: 早期融合图的残余结构误差与桥编辑步数之间的关系。

MMSB-Graph 在该设定下平均需要 5.46 步图编辑，平均路径能量为 1.21。相比只看最终 F1，路径能量提供了额外诊断：如果某个样例需要过多编辑才能恢复标准图，即使最终指标为 1，也说明初始多模态解析质量较差。图 3 进一步显示，语音单模态相对

草图单模态主要改善边恢复和修改成本，早期融合提高了节点覆盖但仍保留方向错误；桥修复阶段则把高维图编辑误差压缩到目标点。桥编辑步数与早期融合图的残余图编辑距离呈正相关，说明路径负载可以作为多模态解析质量的诊断量，而不只是最终指标的附属记录。

6.2 待运行真实模型实验

真实实验将生成草图单模态、语音单模态和语音-草图联合输入下的结构图，并与人工标注目标图比较。关键对照包括：去掉语音反馈、去掉草图保持、去掉路径能量、去掉多边际约束，以及只用最终一致性不约束路径的变体。若外部模型不可用，论文不得编造真实结果，只保留本节协议和合成条件图可控验证。

7 局限与展望

当前工作仍是小样本方法原型。第一，本文没有训练像素级扩散薛定谔桥，图像生成只作为可视化后处理，核心科研对象是可编辑图结构。第二，合成条件图使用人工标注图作为可控目标，因此结果只证明指标和桥过程有效，不证明真实视觉语言模型已达到同等性能。第三，当前语音数据仍偏理想化，真实语音识别鲁棒性需要真人录音或多音色合成语音补测。第四，节点标签匹配仍以字符串和轻量相似度为主，后续应加入语义嵌入和人工修改轨迹。

8 结论

本文将语音辅助草图结构化重新表述为多模态薛定谔桥问题：草图提供空间结构，语音提供反馈锚点，目标方法图提供可编辑图结构约束。我们实现了 MMSB-Graph 的最小可复现实验框架，新增 24 个科研样例、图编辑桥和指标协议，并将系统实现总结提升为方法型论文草稿。后续工作将集中在真实视觉语言模型和语音识别评测、用户修改成本采集和更强的语义图编辑搜索。

参考文献

- [1] Jun Hyeong Kim, Seonghwan Kim, Seokhyun Moon, Hyeongwoo Kim, Jeheon Woo, and Woo Youn Kim. Discrete diffusion Schrödinger bridge matching for graph transformation. In *International Conference on Learning Representations*, 2025.
- [2] Byoungwoo Park and Juho Lee. Multi-marginal Schrödinger bridge matching. *arXiv preprint arXiv:2510.16587*, 2025.

- [3] Itsumi Saito, Haruto Yoshida, and Keisuke Sakaguchi. Sketch2diagram: Generating vector diagrams from hand-drawn sketches. In *International Conference on Learning Representations*, 2025.
- [4] Cheng Tan, Qi Chen, Jingxuan Wei, Gaowei Wu, Zhangyang Gao, Siyuan Li, Bihui Yu, Ruifeng Guo, and Stan Z. Li. Sketchagent: Generating structured diagrams from hand-drawn sketches. *arXiv preprint arXiv:2508.01237*, 2025.
- [5] Panagiotis Theodoropoulos, Nikolaos Komianos, Vincent Pacelli, Guan-Horng Liu, and Evangelos A. Theodorou. Feedback Schrödinger bridge matching. *arXiv preprint arXiv:2410.14055*, 2025.
- [6] Panagiotis Theodoropoulos, Augustinos Saravanos, Evangelos A. Theodorou, and Guan-Horng Liu. Momentum multi-marginal Schrödinger bridge matching. In *Advances in Neural Information Processing Systems*, 2025.